

## PERAMALAN PENJUALAN PRODUK MENGGUNAKAN EXTREME GRADIENT BOOSTING (XGBOOST) DAN KERANGKA KERJA CRISP-DM UNTUK PENGOPTIMALAN MANAJEMEN PERSEDIAAN (STUDI KASUS: UB MART)

Raihan Winurputra<sup>\*1</sup>, Dian Eka Ratnawati<sup>2</sup>

<sup>1,2</sup>Universitas Brawijaya, Malang  
Email: <sup>1</sup>raihanwinurputra@gmail.com, <sup>2</sup>dian\_ilkom@ub.ac.id  
<sup>\*</sup>Penulis Korespondensi

(Naskah masuk: 26 November 2024, diterima untuk diterbitkan: 13 April 2025)

### Abstrak

Manajemen persediaan merupakan masalah yang umum dihadapi oleh bisnis ritel. UB Mart, sebuah bisnis ritel di Kota Malang mengalami permasalahan manajemen persediaan utamanya terkait persediaan produk yang kurang pada produk dengan perputaran penjualan yang sangat cepat. Manajemen persediaan pada UB Mart belum dilakukan menggunakan metode sistematis berbasis data, melainkan masih berdasarkan insting dan intuisi dari pengelola. Upaya yang dapat dilakukan untuk mengatasi permasalahan tersebut adalah dengan melakukan peramalan penjualan. Penelitian bertujuan untuk melakukan peramalan penjualan produk menggunakan model pembelajaran mesin *Extreme Gradient Boosting* (XGBoost) yang dikombinasikan dengan kerangka kerja *Cross-Industry Process for Data Mining* (CRISP-DM) sebagai pedoman manajemen proyek. Peramalan penjualan dilakukan dengan memanfaatkan data historis penjualan UB Mart dari bulan Januari 2020 hingga Juni 2023 terhadap 10 produk terpilih. Proses peramalan dilakukan melalui fase utama kerangka kerja CRISP-DM yaitu *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*. Fase *Modeling* melibatkan pengujian penggunaan fitur untuk melatih model dengan performa terbaik. Hasil penelitian menunjukkan penerapan kerangka kerja CRISP-DM dapat memfasilitasi proses peramalan yang terstruktur serta memperkuat validitas hasil dalam konteks bisnis UB Mart. Fitur penanda jumlah transaksi dan fitur penanda transaksi dengan volume besar menunjukkan peran yang signifikan dalam melatih model XGBoost dengan performa terbaik. Model dengan performa terbaik memiliki nilai rata-rata *Mean Absolute Error* sebesar 11,58 dan nilai rata-rata *Root Mean Squared Error* sebesar 29,19 yang menunjukkan bahwa model memiliki kemampuan peramalan yang baik.

**Kata kunci:** bisnis ritel, peramalan, *Extreme Gradient Boosting*, *Cross-Industry Process for Data Mining*

### PRODUCT SALES FORECASTING USING EXTREME GRADIENT BOOSTING (XGBOOST) AND CRISP-DM FRAMEWORK FOR INVENTORY MANAGEMENT OPTIMIZATION (CASE STUDY: UB MART)

#### Abstract

Inventory management is a common issue faced by retail businesses. UB Mart, a retail business in Kota Malang, is experiencing inventory management problems, particularly related to product shortages on product that have fast sales turnover. Inventory management at UB Mart has not yet been conducted using a systematic, data-driven method, but rather relies solely on the intuition and instincts of the management. One approach to addressing that problem is implementing sales forecasting. This research aims to forecast product sales using the *Extreme Gradient Boosting* (XGBoost) machine learning model, combined with the *Cross-Industry Process for Data Mining* (CRISP-DM) framework as project management guideline. The sales forecasting uses UB Mart's historical sales data from January 2020 to June 2023 for 10 selected products. The forecasting process follows the main phases of the CRISP-DM framework: *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, and *Deployment*. The *Modeling* phase involves testing feature selection to train the model that can deliver best performance. The results of this research demonstrate that applying the CRISP-DM framework facilitates a structured forecasting process and enhances the validity of the forecast in the context of UB Mart's business. Transaction count indicators and bulk transaction indicators significantly contribute to training the best-performing XGBoost model. The best-performing model achieved an average *Mean Absolute Error* of 11,58 and an average *Root Mean Squared Error* of 29,19, indicating the model's good ability to forecast.

**Keywords:** retail business, forecasting, *Extreme Gradient Boosting*, *Cross-Industry Process for Data Mining*

## 1. PENDAHULUAN

Dunia industri telah mengalami banyak perubahan dan perkembangan dalam beberapa dekade terakhir. Perubahan dan perkembangan yang terjadi meliputi globalisasi, perubahan ekonomi, dan perkembangan penggunaan teknologi, sehingga menuntut pelaku industri untuk dapat lebih responsif dan adaptif terhadap perubahan perilaku pelanggan (Guinoubi, Hani dan Elmhamedi, 2021). Bisnis ritel merupakan salah satu bagian dari dunia industri yang saat ini mengalami perubahan dan perkembangan yang sangat pesat.

Bisnis ritel harus menghadapi berbagai tantangan agar dapat bertahan dalam persaingan industri yang semakin ketat. Salah satu tantangan yang harus dihadapi oleh bisnis ritel adalah permasalahan terkait ketersediaan (*availability*) produk guna memenuhi kebutuhan dan permintaan pelanggan (Fernie dan Sparks, 2019). Ketersediaan produk pada bisnis ritel berkaitan dengan proses manajemen persediaan. Manajemen persediaan dapat menjadi permasalahan bagi bisnis ritel apabila tidak dilakukan dan dikelola dengan tepat serta efisien. Persediaan produk yang kurang dapat berdampak pada pelanggan yang kecewa karena tidak mendapatkan produk yang diinginkan (Husein, Lubis dan Harahap, 2021). Persediaan produk yang berlebih dapat berdampak pada penggunaan penyimpanan yang lebih banyak sehingga meningkatkan biaya operasional (Fernie dan Sparks, 2019).

Permasalahan manajemen persediaan pada bisnis ritel disebabkan oleh permintaan pelanggan yang cenderung fluktuatif (Heriansyah dan Hasibuan, 2018). Permintaan pelanggan yang fluktuatif mengharuskan pengelola bisnis ritel untuk memiliki keterampilan pengambilan keputusan yang kuat dan baik guna menghadapi ketidakpastian di masa yang akan datang (Hajjah dan Marlim, 2021). Salah satu upaya yang dapat digunakan untuk membantu proses pengambilan keputusan manajemen persediaan adalah melalui peramalan penjualan.

Peramalan merupakan proses untuk memperkirakan nilai atau kejadian di masa yang akan datang dengan seakurat mungkin berdasarkan informasi yang dimiliki seperti data historis maupun faktor yang dapat memengaruhi perkiraan (Hyndman dan Athanasopoulos, 2021). Peramalan penjualan yang akurat memungkinkan pengelola bisnis ritel untuk memperoleh keunggulan kompetitif dan meningkatkan peluang keberhasilan berdasarkan wawasan (*insight*) yang diperoleh. Peramalan penjualan yang akurat, efektif, dan efisien dapat dicapai melalui pendekatan sains data (*data science*) serta penerapan metode pembelajaran mesin (*machine learning*). Sains data memberikan peluang untuk mengungkap dan mengidentifikasi wawasan dari data historis yang dapat digunakan untuk meramalkan penjualan di masa yang akan datang (Riza, 2022).

Studi kasus pada penelitian ini adalah UB Mart. UB Mart merupakan sebuah bisnis ritel di Kota Malang yang dikelola oleh Koperasi Jasa Pegawai Republik Indonesia Universitas Brawijaya (KJPRI UB). UB Mart sebagai bisnis ritel juga menghadapi tantangan dan permasalahan terkait bisnis ritel yang telah diuraikan sebelumnya, utamanya terkait persediaan produk yang kurang. Upaya yang telah dilakukan oleh UB Mart untuk mengatasi permasalahan manajemen persediaan belum dilakukan secara efektif dan efisien. UB Mart belum memiliki metode dan pedoman yang baku dalam proses manajemen persediaan. Manajemen persediaan produk pada UB masih mengandalkan prediksi yang didasarkan pada insting dan intuisi dari pengelola saja dalam proses pengambilan keputusan. Prediksi yang didasarkan hanya pada intuisi dan insting tentunya tidak dapat memberikan hasil yang baik dan tepat, terlihat dari UB Mart yang masih belum optimal dalam melakukan manajemen persediaan. Berdasarkan fenomena dan permasalahan yang telah diuraikan, penulis tertarik untuk melakukan peramalan penjualan pada UB Mart dengan pendekatan sains data menggunakan metode *Extreme Gradient Boosting* (XGBoost) dan kerangka kerja *Cross-Industry Process for Data Mining* (CRISP-DM) guna mengoptimalkan manajemen persediaan produk pada UB Mart yang lebih efektif, efisien, dan akurat berdasarkan data.

Penelitian yang dilakukan berfokus pada penerapan kerangka kerja CRISP-DM untuk melakukan peramalan penjualan produk pada UB Mart, mengidentifikasi fitur-fitur pelatihan model yang memiliki peran serta pengaruh signifikan dalam menghasilkan model XGBoost dengan performa terbaik untuk peramalan penjualan pada UB Mart, serta mengevaluasi performa model dalam meramalkan penjualan produk pada UB Mart. Fokus penelitian yang dilakukan adalah pengembangan model peramalan yang dapat menghasilkan peramalan penjualan terbaik.

## 2. LANDASAN PUSTAKA

### 2.1. Kajian Pustaka

Penelitian terdahulu yang relevan dengan topik penelitian ini telah ditinjau dan dipelajari sebagai rujukan dan referensi. Temuan dari beberapa penelitian terdahulu menunjukkan bahwa peramalan penjualan menggunakan metode XGBoost memberikan hasil serta performa yang baik dan memuaskan.

Yang (2023) melakukan penelitian peramalan penjualan pada Walmart dengan membandingkan metode *Ordinary Least Squares* (OLS), *Random Forest*, dan XGBoost. Evaluasi performa model menunjukkan bahwa XGBoost memiliki performa terbaik, dengan nilai *Mean Absolute Error* (MAE) sebesar 0,1246 (Yang, 2023).

Purnamasari et al. (2023) merekomendasikan penggunaan XGBoost untuk peramalan permintaan pada sebuah Usaha Kecil dan Menengah (UKM) di bidang kerajinan kulit di Yogyakarta. Penelitian tersebut membandingkan beberapa metode, antara lain *Seasonal Autoregressive Integrated Moving Average* (SARIMA), *Seasonal Autoregressive Integrated Moving Average with eXogenous regressors* (SARIMAX), *Long Short Term Memory* (LSTM), XGBoost, dan *Gaussian Process Regression* (GPR) untuk peramalan permintaan, serta menerapkan kerangka kerja CRISP-DM. Evaluasi performa model menggunakan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) menunjukkan bahwa XGBoost memberikan hasil peramalan dan kinerja yang lebih baik dibandingkan metode lainnya (Purnamasari et al., 2023).

Zhang et al. (2021) melakukan penelitian untuk melakukan peramalan volume penjualan toko ritel menggunakan beberapa metode yaitu *Autoregressive Integrated Moving Average* (ARIMA), *Long Short Term Memory* (LSTM), *Prophet*, *Gradient Boosted Decision Tree* (GBDT), dan XGBoost. XGBoost menunjukkan performa yang lebih baik dibandingkan dengan metode lain yang digunakan, dengan RMSE sebesar 0,225582 dan MAE sebesar 0,178667 (Zhang et al., 2021).

## 2.2. Peramalan

Peramalan adalah ilmu yang digunakan untuk memperkirakan kejadian di masa mendatang. Peramalan melibatkan penggunaan data historis untuk memproyeksikan masa yang akan datang menggunakan model matematika (Heizer, Render dan Munson, 2017). Peramalan dapat dianggap efektif jika hasil peramalan mendekati nilai aktual dan dapat menangkap pola serta hubungan yang ada dalam data historis, tanpa mereplikasi kejadian masa lalu yang tidak akan terjadi lagi (Hyndman dan Athanasopoulos, 2021).

## 2.3. Extreme Gradient Boosting

*Extreme Gradient Boosting* (XGBoost) merupakan metode pembelajaran mesin populer yang banyak digunakan saat ini. XGBoost merupakan model yang digunakan untuk mengatasi masalah *supervised learning* dengan memanfaatkan data latih (*training data*)  $x_i$  untuk memprediksi variabel target  $y_i$ . Prinsip dasar pelatihan XGBoost adalah menemukan parameter  $\theta$  terbaik yang paling sesuai dengan data latih dan variabel target (XGBoost Developers, 2022).

XGBoost menggunakan model yang lebih terstandar dalam membangun struktur pohon regresi, sehingga dapat meningkatkan performa dan mengurangi kompleksitas model untuk mencegah *overfitting* (Yulianti, Soesanto dan Sukmawaty, 2022). Konstruksi struktur pohon regresi pada

XGBoost secara matematis dapat dinyatakan dalam Persamaan (1).

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in \mathcal{F} \quad (1)$$

Pada Persamaan (1),  $\hat{y}_i$  merupakan nilai prediksi,  $K$  merupakan jumlah pohon regresi,  $f_k$  merupakan struktur pohon regresi, dan  $\mathcal{F}$  merupakan himpunan seluruh kemungkinan pohon regresi.

XGBoost melatih model dengan mendefinisikan fungsi objektif (*objective function*) dan kemudian mengoptimalkannya. Fungsi objektif digunakan untuk mengukur seberapa baik model tersebut dapat sesuai (*fit*) dengan data latih. Fungsi objektif XGBoost dapat dinyatakan dalam Persamaan (2).

$$obj(\theta) = L(\theta) + \Omega(\theta) \quad (2)$$

Pada Persamaan (2),  $obj(\theta)$  merupakan fungsi objektif dengan parameter model  $\theta$ ,  $L(\theta)$  merupakan fungsi kerugian dan  $\Omega(\theta)$  merupakan regularisasi.

## 2.4. Evaluasi Performa Model

### 1) Mean Absolute Error (MAE)

*Mean Absolute Error* (MAE) merupakan rata-rata selisih absolut antara nilai prediksi model dan nilai aktual dari data. MAE dapat dihitung menggunakan Persamaan (3).

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$

Pada Persamaan (3),  $n$  merupakan jumlah data yang diamati,  $y_i$  merupakan nilai aktual,  $\hat{y}_i$  merupakan nilai hasil prediksi.

### 2) Root Mean Squared Error (RMSE)

*Root Mean Squared Error* (RMSE) merupakan akar kuadrat dari rata-rata selisih kuadrat antara nilai prediksi model dan nilai aktual dari data yang diamati. RMSE dapat dihitung menggunakan Persamaan (4).

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4)$$

Pada Persamaan (4),  $n$  merupakan jumlah data yang diamati,  $y_i$  merupakan nilai aktual,  $\hat{y}_i$  merupakan nilai hasil prediksi.

## 2.5. CRISP-DM

*Cross-Industry Standard Process for Data Mining* (CRISP-DM) adalah kerangka kerja yang umum digunakan dalam proyek sains data dan penambangan data (Martinez-Plumed et al., 2021). CRISP-DM terdiri dari enam fase sebagai berikut:

### 1) Business Understanding

Fase *Business Understanding* dilakukan untuk mendapatkan pemahaman mendalam tentang tujuan

bisnis, tantangan yang dihadapi, dan persyaratan yang harus dipenuhi dalam proyek.

## 2) Data Understanding

Fase *Data Understanding* merupakan proses pengumpulan data dilanjutkan dengan aktivitas untuk memahami dan membiasakan diri dengan data yang akan digunakan dalam proyek.

## 3) Data Preparation

Fase *Data Preparation* mencakup seluruh aktivitas untuk membangun dan mempersiapkan set data akhir (data yang akan digunakan dalam fase *Modeling*).

## 4) Modeling

Fase *Modeling* dilakukan untuk penerapan dan pengembangan model atau teknik analisis yang sesuai untuk mengatasi permasalahan bisnis yang diidentifikasi.

## 5) Evaluation

Fase *Evaluation* merupakan fase pemeriksaan menyeluruh terhadap model dan hasil analisis yang diperoleh untuk menilai kualitas dan performa hasil *Modeling* dalam kaitannya dengan tujuan bisnis yang telah diidentifikasi.

## 6) Deployment

Fase *Deployment* adalah fase implementasi hasil model dan hasil analisis ke dalam lingkungan bisnis.

Urutan fase CRISP-DM tidak bersifat kaku, sehingga memungkinkan alur kerja proyek bergerak maju atau mundur di antara fase yang berbeda dalam implementasinya (Chapman et al., 2000).

## 3. TABEL DAN GAMBAR

Tahapan penelitian yang dilalui dalam penelitian ini diilustrasikan dalam diagram alir pada Gambar 1.

Penjelasan Gambar 1 terkait diagram alir penelitian adalah sebagai berikut:

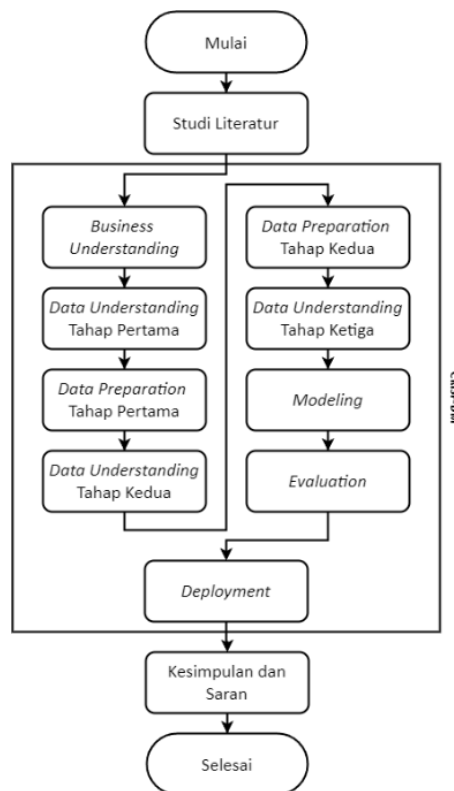
### 3.1. Business Understanding

Fase *Business Understanding* terdiri dari dua proses yaitu penentuan tujuan bisnis dan pendefinisian tujuan proyek. Fase *Business Understanding* dilakukan melalui wawancara terhadap manajer toko UB Mart.

### 3.2. Data Understanding Tahap Pertama

Fase *Data Understanding* tahap pertama terdiri dari empat proses yaitu pengumpulan data, pengintegrasian data, pendeskripsian data, dan pengeksploasian data. Pengumpulan data dilakukan melalui studi dokumen. Dokumen yang digunakan dalam penelitian ini meliputi catatan penjualan produk pada UB Mart dari bulan Januari 2020 sampai dengan bulan Juni 2023. Dokumen lain yang digunakan adalah Surat Keputusan Bersama Menteri Agama, Menteri Ketenagakerjaan, dan Menteri

Pendayagunaan Aparatur Negara dan Reformasi Birokrasi Republik Indonesia tentang hari libur nasional dan cuti bersama pada tahun 2020 sampai dengan tahun 2023. Proses pengeksploasian data dilakukan dengan memeriksa nilai yang hilang (*missing value*) dan memeriksa pencilan (*outlier*).



Gambar 1. Diagram Alir Tahapan Penelitian

### 3.3. Data Preparation Tahap Pertama

Fase *Data Preparation* tahap pertama terdiri dari empat proses yaitu pemformatan data, pembersihan data, pengelompokan data, dan pemilihan data. Pembersihan data dilakukan untuk mengatasi nilai yang hilang dan mengatasi pencilan. Pengelompokan data dilakukan untuk mengelompokkan data penjualan berdasarkan produk dan tanggal penjualan. Pemilihan data dilakukan untuk memilih data dari produk yang akan diramalkan. Produk yang akan diramalkan adalah sebanyak 10 produk dengan kriteria pemilihan produk adalah 4 produk dengan kuantitas penjualan tertinggi, 3 produk dengan frekuensi penjualan tertinggi, dan 3 produk pilihan pemangku kepentingan UB Mart. Sepuluh produk yang telah terpilih adalah 3 produk air mineral, 2 produk mi instan, 1 produk minuman rasa buah, 1 produk gula pasir, 1 produk telur, 1 produk beras, dan 1 produk minyak goreng.

### 3.4. Data Understanding Tahap Kedua

Fase *Data Understanding* tahap kedua terdiri dari proses pemeriksaan deret waktu yang hilang pada data produk terpilih.

### 3.5. Data Preparation Tahap Kedua

Fase *Data Preparation* tahap kedua terdiri empat proses yaitu penanganan deret waktu yang hilang, transformasi logaritmik, perekayasa fitur, dan pembuatan data terpisah untuk setiap produk terpilih. Penanganan deret waktu yang hilang dilakukan dengan membuat baris data baru untuk setiap deret waktu yang hilang dan menetapkan nilai kuantitas penjualan bernilai 0. Transformasi logaritmik dilakukan terhadap kolom variabel target yaitu kolom berisi kuantitas penjualan. Perekayasa fitur dilakukan untuk membuat fitur yang akan digunakan dalam proses pelatihan model. Terdapat 3 jenis fitur yang dibuat yaitu fitur deret waktu, fitur lag, dan fitur penanda. Fitur yang dibuat pada proses perekayasa fitur ditunjukkan pada Tabel 1.

Tabel 1. Fitur Hasil Perekayasa Fitur

Fitur	Keterangan
<b>Fitur Deret Waktu</b>	
Day	Hari dalam satu bulan
Day_of_week	Hari dalam satu minggu
Month	Bulan
Year	Tahun
Is_weekend	Akhir pekan
<b>Fitur Lag</b>	
Lag_Qty_1	Kuantitas penjualan pada 1 hari yang lalu
Lag_Qty_7	Kuantitas penjualan pada 7 hari yang lalu
Lag_Qty_30	Kuantitas penjualan pada 30 hari yang lalu
Lag_Qty_365	Kuantitas penjualan pada 365 hari yang lalu
<b>Fitur Penanda</b>	
Is_Holiday	Penanda hari libur
No_Sales	Penanda ada tidaknya penjualan
Store_Closed	Penanda toko tutup
Num_Transaction	Penanda jumlah transaksi
Num_Bulk_Trans	Penanda transaksi dengan volume besar

### 3.6. Data Understanding Tahap Ketiga

Fase *Data Understanding* tahap ketiga terdiri dari dua proses yaitu analisis statistik deskriptif dan analisis visualisasi *STL Decomposition* terhadap data penjualan produk terpilih.

### 3.7. Modeling

Fase *Modeling* dilakukan secara terpisah untuk setiap produk yang dipilih. Fase *Modeling* terdiri dari proses-proses seperti pembagian data menjadi data latih dan data uji, pelatihan model XGBoost menggunakan data latih, peramalan terhadap data uji, dan perhitungan nilai evaluasi performa model. Fase *Modeling* dilakukan melalui tahap pengujian pelatihan model.

### 3.8. Evaluation

Fase *Evaluation* terdiri dari dua proses yaitu evaluasi hasil pelatihan model XGBoost dan pemilihan model XGBoost dengan performa terbaik.

### 3.9. Deployment

Fase *Deployment* terdiri dari proses melakukan peramalan untuk masa yang akan datang menggunakan model terpilih.

## 4. PENGUJIAN DAN HASIL

### 4.1. Tujuan Bisnis dan Tujuan Proyek

UB Mart, sebagai bisnis ritel, menghadapi masalah dalam manajemen persediaan produk, khususnya kekurangan persediaan produk. Beberapa upaya sementara telah dilakukan UB Mart untuk menghadapi masalah tersebut seperti menawarkan produk alternatif, memesan produk secara langsung ke pemasok, atau membeli dari pasar grosir, namun upaya tersebut sering kali kurang efektif. UB Mart melakukan pengadaan stok satu hingga dua minggu sekali dan keputusan manajemen persediaan masih berdasarkan insting dan intuisi pengelola. Hal tersebut menyebabkan inefisiensi dan inkonsistensi pada proses manajemen persediaan. Oleh karena itu, UB Mart memerlukan metode manajemen persediaan yang sistematis dan berbasis data untuk peramalan penjualan yang akurat, guna meningkatkan kepuasan pelanggan dan efisiensi operasional toko.

Berdasarkan tujuan bisnis yang telah diidentifikasi, tujuan proyek yang dilakukan adalah menerapkan metodologi sistematis berbasis data untuk membantu manajemen persediaan produk pada UB Mart melalui peramalan penjualan produk. Peramalan penjualan dilakukan dengan memanfaatkan data historis penjualan serta faktor eksternal lainnya yang dapat meningkatkan akurasi peramalan penjualan. Horizon waktu peramalan yang dilakukan adalah 14 hari atau dua minggu setelah data terakhir pada data historis penjualan. Penentuan horizon waktu peramalan dilakukan berdasarkan siklus pengadaan persediaan produk pada UB Mart yang umumnya dilakukan setiap 14 hari atau 2 minggu sekali. Peramalan penjualan tidak dilakukan terhadap seluruh produk, melainkan hanya dilakukan terhadap 10 produk terpilih.

### 4.2. Proses Pengujian

Proses pengujian dilakukan pada fase *Modeling* dengan melatih model XGBoost melalui empat skenario pengujian. Skenario pengujian merujuk pada penggunaan fitur untuk melatih model XGBoost yang diharapkan dapat menghasilkan model XGBoost dengan performa terbaik dalam melakukan peramalan. Proses pengujian dilakukan secara terpisah untuk setiap skenario pengujian dan setiap produk. Skenario pengujian yang dilakukan adalah sebagai berikut:

#### 1) Skenario 1

Skenario 1 merupakan pengujian *Modeling* dengan menggunakan fitur deret waktu saja untuk melatih model XGBoost. Fitur deret waktu meliputi 'Day', 'Day\_of\_week', 'Month', 'Year', dan 'Is\_weekend'.

#### 2) Skenario 2

Skenario 2 merupakan pengujian *Modeling* dengan menggunakan kombinasi fitur deret waktu

dan fitur lag untuk melatih model XGBoost. Fitur lag meliputi ‘Lag\_Qty\_1’, ‘Lag\_Qty\_7’, ‘Lag\_Qty\_30’, dan ‘Lag\_Qty\_365’.

3) Skenario 3

Skenario 3 merupakan pengujian *Modeling* dengan menggunakan kombinasi fitur deret waktu dan fitur penanda. Fitur penanda meliputi ‘Is\_Holiday’, ‘No\_Sales’, ‘Store\_Closed’, ‘Num\_Transaction’, dan ‘Num\_Bulk\_Trans’.

4) Skenario 4

Skenario 4 merupakan pengujian *Modeling* dengan menggunakan kombinasi fitur deret waktu, fitur lag, dan fitur penanda.

XGBoost adalah model yang digunakan untuk pemodelan. Pelatihan model dilakukan dengan memisahkan data penjualan untuk setiap produk menjadi data latih dan data uji, dengan titik pemisahan ditetapkan pada tanggal 31-05-2022. Data latih terdiri dari 882 baris mulai dari data pada tanggal 01-01-2020 hingga 31-05-2022. Data uji terdiri dari 395 baris mulai dari data pada tanggal 01-06-2022 hingga 30-06-2023.

Metode evaluasi yang digunakan dalam pengujian adalah *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE). Evaluasi performa model juga akan dilakukan dengan menghitung nilai *feature importance* dari setiap fitur yang digunakan untuk melatih model. *Feature importance* memberikan wawasan terkait kontribusi setiap fitur dalam melatih model. Nilai *feature importance* yang semakin tinggi menandakan bahwa fitur memiliki pengaruh yang semakin tinggi dalam pembangunan model.

**4.3. Hasil Pengujian**

Pengujian *Modeling* dilakukan terhadap 10 produk terpilih menggunakan empat skenario pengujian yang telah ditentukan. Analisis hasil pengujian dilakukan terhadap 2 dari 10 produk terpilih yang dianggap dapat mewakili produk lain. Produk yang akan dianalisis adalah produk air mineral botol kemasan sedang dan produk mi instan varian goreng.

1) Produk Air Mineral

Hasil pengujian *Modeling* pada produk air mineral ditunjukkan pada Tabel 2.


Analisis hasil pengujian *Modeling* produk air mineral untuk setiap skenario pengujian adalah sebagai berikut:

a. Skenario 1

Visualisasi hasil peramalan terhadap data uji produk air mineral berdasarkan pengujian skenario 1 ditunjukkan pada Gambar 2. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 1.

Tabel 2. Hasil Pengujian *Modeling* Produk Air Mineral

Skenario Pengujian	Nilai Evaluasi Performa		Hasil <i>Feature Importance</i>	
	MAE	RMSE	Fitur	Importance
Skenario 1	152,59	412,93	Day_of_week	0,595063
			Year	0,172743
			Month	0,158500
			Day	0,073694
Skenario 2	152,24	412,58	Day_of_week	0,387316
			Year	0,113557
			Month	0,100038
			Lag_Qty_7	0,094536
Skenario 3	83,94	224,65	Num_Bulk_Trans	0,909635
			Num_Transaction	0,064194
			Day	0,009578
			Year	0,006388
Skenario 4	86,78	263,33	Num_Bulk_Trans	0,886382
			Num_Transaction	0,067036
			Day	0,010814
			Year	0,007240




Gambar 2. Visualisasi Hasil Peramalan Pengujian Skenario 1 terhadap Data Uji Produk Air Mineral

Visualisasi hasil peramalan pada Gambar 2 menunjukkan bahwa model memiliki kemampuan yang buruk untuk melakukan peramalan terhadap data uji. Model terlihat tidak mampu untuk mengidentifikasi dan mempelajari pola dan tren utama dalam data. Visualisasi hasil peramalan selaras dengan nilai evaluasi performa model pada Tabel 2 yang menunjukkan nilai MAE sebesar 152,59 dan nilai RMSE sebesar 412,93. Nilai evaluasi performa model menunjukkan bahwa rata-rata hasil peramalan menyimpang 152,59 unit (MAE) dan 412,93 unit (RMSE) dari data uji setiap harinya. Dalam konteks bisnis untuk produk air mineral, penyimpangan ini menunjukkan bahwa peramalan yang dihasilkan model dengan pengujian skenario 1 cenderung tidak akurat, dengan penyimpangan nilai peramalan yang jauh lebih tinggi dibandingkan rata-rata penjualan harian sebesar 157,26 unit. Analisis nilai *feature importance* dari pengujian skenario 1 pada Tabel 2 menunjukkan bahwa fitur dengan nilai *feature importance* tertinggi adalah fitur ‘Day\_of\_week’. Fitur ‘Day\_of\_week’ memiliki pengaruh terbesar dalam model dibandingkan dengan fitur yang lain, namun model yang dihasilkan memiliki performa yang tidak baik.

b. Skenario 2

Visualisasi hasil peramalan terhadap data uji produk air mineral berdasarkan pengujian skenario 2 ditunjukkan pada Gambar 3. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna

merah merupakan grafik hasil peramalan dengan pengujian skenario 2.




Gambar 3. Visualisasi Hasil Peramalan Pengujian Skenario 2 terhadap Data Uji Produk Air Mineral

Visualisasi hasil peramalan pada Gambar 3 menunjukkan hasil yang tidak jauh berbeda dengan pengujian menggunakan skenario 1. Berdasarkan Tabel 2, nilai MAE dan RMSE pengujian skenario 2 menunjukkan penurunan yang tidak signifikan dibandingkan model dengan skenario 1. Hal tersebut mengindikasikan bahwa model skenario 2 hanya sedikit lebih baik dibandingkan model dengan skenario 1.

#### c. Skenario 3

Visualisasi hasil peramalan terhadap data uji produk air mineral berdasarkan pengujian skenario 3 ditunjukkan pada Gambar 4. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 3.




Gambar 4. Visualisasi Hasil Peramalan Pengujian Skenario 3 terhadap Data Uji Produk Air Mineral

Visualisasi hasil peramalan pada Gambar 4 menunjukkan bahwa model memiliki kemampuan yang cukup baik untuk melakukan peramalan terhadap data uji. Model terlihat sedikit kesulitan untuk mengidentifikasi dan mempelajari pola dan tren utama dalam data. Visualisasi hasil peramalan selaras dengan nilai evaluasi performa model pada Tabel 2 yang menunjukkan nilai MAE sebesar 83,94 dan nilai RMSE sebesar 224,65. Terdapat penurunan nilai MAE dan RMSE yang cukup signifikan dibandingkan model-model sebelumnya. Nilai evaluasi performa model menunjukkan bahwa rata-rata hasil peramalan menyimpang 83,94 unit (MAE) dan 224,65 unit (RMSE) dari data uji setiap harinya. Dalam konteks bisnis untuk produk air mineral, penyimpangan ini menunjukkan bahwa peramalan yang dihasilkan model dengan pengujian skenario 3

cenderung kurang akurat, dengan penyimpangan nilai peramalan yang cukup tinggi dibandingkan rata-rata penjualan harian sebesar 157,26 unit. Analisis nilai *feature importance* dari pengujian skenario 3 pada Tabel 2 menunjukkan bahwa fitur 'Num\_Bulk\_Trans' memiliki nilai *feature importance* tertinggi dibandingkan dengan fitur-fitur yang lain. Nilai *feature importance* yang tinggi pada fitur 'Num\_Bulk\_Trans' menandakan bahwa fitur tersebut memiliki pengaruh terbesar dalam model dan dapat menghasilkan model dengan performa peramalan yang baik.

#### d. Skenario 4

Visualisasi hasil peramalan terhadap data uji produk air mineral berdasarkan pengujian skenario 4 ditunjukkan pada Gambar 5. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 4.



Gambar 5. Visualisasi Hasil Peramalan Pengujian Skenario 4 terhadap Data Uji Produk Air Mineral

Visualisasi hasil peramalan pada Gambar 5 menunjukkan hasil yang tidak jauh berbeda dengan pengujian skenario 3. Berdasarkan Tabel 2, nilai MAE dan RMSE pengujian skenario 4 menunjukkan peningkatan yang tidak signifikan dibandingkan model dengan skenario 3. Hal tersebut mengindikasikan bahwa model skenario 4 sedikit lebih buruk dibandingkan model dengan skenario 3.

#### 2) Produk Mi Instan

Hasil pengujian *Modeling* pada produk mi instan ditunjukkan pada Tabel 3.

Tabel 3. Hasil Pengujian *Modeling* Produk Mi Instan


Skenario Pengujian	Nilai Evaluasi Performa		Hasil <i>Feature Importance</i>	
	MAE	RMSE	Fitur	Importance
Skenario 1	50,35	106,45	Day_of_week	0,788000
			Month	0,108897
			Day	0,051935
			Year	0,051168
Skenario 2	45,06	98,78	Day_of_week	0,552270
			Lag_Qty_1	0,115176
			Month	0,082511
			Lag_Qty_30	0,069900
Skenario 3	12,46	24,36	Num_Transaction	0,762712
			Num_Bulk_Trans	0,219325
			Day	0,007426
			Month	0,004121
Skenario 4	12,18	23,79	Num_Transaction	0,755577
			Num_Bulk_Trans	0,207827
			Day	0,007431
			Lag_Qty_365	0,005661



Analisis hasil pengujian *Modeling* produk mi instan untuk setiap skenario pengujian adalah sebagai berikut:

a. Skenario 1

Visualisasi hasil peramalan terhadap data uji produk mi instan berdasarkan pengujian skenario 1 ditunjukkan pada Gambar 6. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 1.




Gambar 6. Visualisasi Hasil Peramalan Pengujian Skenario 1 terhadap Data Uji Produk Mi Instan

Visualisasi hasil peramalan pada Gambar 6 menunjukkan bahwa model memiliki kemampuan yang buruk untuk melakukan peramalan terhadap data uji. Model terlihat tidak mampu untuk mengidentifikasi dan mempelajari pola dan tren utama dalam data. Visualisasi hasil peramalan selaras dengan nilai evaluasi performa model pada Tabel 3 yang menunjukkan nilai MAE sebesar 50,35 dan nilai RMSE sebesar 106,45. Nilai evaluasi performa model menunjukkan bahwa rata-rata hasil peramalan menyimpang 50,35 unit (MAE) dan 106,45 unit (RMSE) dari data uji setiap harinya. Dalam konteks bisnis untuk produk mi instan, penyimpangan ini menunjukkan bahwa peramalan yang dihasilkan model dengan pengujian skenario 1 cenderung kurang akurat, dengan penyimpangan nilai peramalan yang relatif tinggi dibandingkan rata-rata penjualan harian sebesar 65,86 unit. Analisis nilai *feature importance* dari pengujian skenario 1 pada Tabel 3 menunjukkan bahwa fitur 'Day\_of\_week' memiliki nilai *feature importance* yang paling tinggi. Tingginya nilai *feature importance* pada fitur 'Day\_of\_week' menunjukkan bahwa fitur tersebut memiliki pengaruh terbesar dalam model, namun model yang dihasilkan memiliki performa yang tidak baik.

b. Skenario 2

Visualisasi hasil peramalan terhadap data uji produk mi instan berdasarkan pengujian skenario 2 ditunjukkan pada Gambar 7. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 2.




Gambar 7. Visualisasi Hasil Peramalan Pengujian Skenario 2 terhadap Data Uji Produk Mi Instan

Visualisasi hasil peramalan pada Gambar 7 menunjukkan hasil yang tidak jauh berbeda dengan pengujian menggunakan skenario 1. Berdasarkan Tabel 3, nilai MAE dan RMSE pengujian skenario 2 menunjukkan penurunan yang tidak signifikan dibandingkan model dengan skenario 1. Hal tersebut mengindikasikan bahwa model skenario 2 hanya sedikit lebih baik dibandingkan model dengan skenario 1.

c. Skenario 3

Visualisasi hasil peramalan terhadap data uji produk mi instan berdasarkan pengujian skenario 3 ditunjukkan pada Gambar 8. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 3.



Gambar 8. Visualisasi Hasil Peramalan Pengujian Skenario 3 terhadap Data Uji Produk Mi Instan


Visualisasi hasil peramalan pada Gambar 8 menunjukkan bahwa model memiliki kemampuan yang baik untuk melakukan peramalan terhadap data uji. Model secara umum terlihat dapat mengidentifikasi dan mempelajari pola dan tren utama dalam data secara akurat. Visualisasi hasil peramalan selaras dengan nilai evaluasi performa model pada Tabel 3 yang menunjukkan nilai MAE sebesar 12,46 dan nilai RMSE sebesar 24,36. Terdapat penurunan nilai MAE dan RMSE yang cukup signifikan dibandingkan model-model sebelumnya. Nilai evaluasi performa model menunjukkan bahwa rata-rata hasil peramalan menyimpang 12,46 unit (MAE) dan 24,36 unit (RMSE) dari data uji setiap harinya. Dalam konteks bisnis untuk produk mi instan, penyimpangan ini menunjukkan bahwa peramalan yang dihasilkan model dengan pengujian skenario 3 cenderung baik, dengan penyimpangan nilai peramalan yang rendah



dibandingkan rata-rata penjualan harian sebesar 65,86 unit. Analisis nilai *feature importance* dari pengujian skenario 3 pada Tabel 3 menunjukkan fitur ‘Num\_Transaction’ memiliki nilai *feature importance* yang paling tinggi. Nilai *feature importance* yang tinggi pada fitur ‘Num\_Transaction’ menandakan bahwa fitur ‘Num\_Transaction’ memiliki pengaruh terbesar dalam model dan dapat menghasilkan model dengan performa peramalan yang baik.

#### d. Skenario 4

Visualisasi hasil peramalan terhadap data uji mi instan menggunakan pengujian skenario 4 ditunjukkan pada Gambar 9. Grafik berwarna biru merupakan grafik data uji, sementara grafik berwarna merah merupakan grafik hasil peramalan dengan pengujian skenario 4.



Gambar 9. Visualisasi Hasil Peramalan Pengujian Skenario 4 terhadap Data Uji Produk Mi Instan

Visualisasi hasil peramalan pada Gambar 9 menunjukkan hasil yang tidak jauh berbeda dengan pengujian menggunakan skenario 3. Berdasarkan Tabel 3, nilai MAE dan RMSE pengujian skenario 4 menunjukkan penurunan yang tidak signifikan dibandingkan model dengan skenario 3. Hal tersebut mengindikasikan bahwa model skenario 4 sedikit lebih baik dibandingkan model dengan skenario 3.

#### 4.4. Analisis Hasil Pengujian Modeling

Hasil pengujian *Modeling* terhadap 10 produk terpilih disajikan pada Tabel 5 dan Tabel 6 yang secara berturut-turut menyajikan informasi rekapitulasi hasil pengujian *Modeling* dan rekapitulasi nilai *feature importance*. Tabel 5 dan Tabel 6 memiliki kolom “Produk” yang berisi kode untuk setiap produk terpilih guna menyederhanakan penyajian data. Arti dari setiap kode produk dapat dilihat pada Tabel 4 dan digunakan secara konsisten di Tabel 5 dan Tabel 6.

Tabel 4. Arti Kode Produk

Produk	Keterangan
A	Produk air mineral kemasan botol ukuran sedang
B	Produk mi instan varian goreng
C	Produk air mineral kemasan gelas
D	Produk minuman rasa buah
E	Produk gula pasir
F	Produk telur
G	Produk air mineral kemasan botol ukuran besar
H	Produk beras
I	Produk minyak goreng
J	Produk mi instan varian rebus

Rekapitulasi hasil pengujian *Modeling* untuk setiap skenario dan setiap produk ditunjukkan pada Tabel 5.

Tabel 5. Rekapitulasi Hasil Evaluasi Performa Pengujian *Modeling*

Produk	Rata-Rata Penjualan	Skenario 1		Skenario 2		Skenario 3		Skenario 4	
		MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
A	157,26	152,59	412,93	152,24	412,58	83,94	224,65	86,78	263,33
B	65,86	50,35	106,45	45,06	98,78	12,46	24,36	12,18	23,79
C	6,79	6,53	20,41	6,55	20,43	2,48	8,70	2,88	11,72
D	1,32	1,28	4,93	1,25	4,99	0,22	1,06	0,19	0,76
E	30,67	20,88	52,05	18,46	47,38	5,28	10,39	5,31	11,06
F	14,78	9,09	13,98	8,1	12,53	1,91	3,36	1,91	3,41
G	22,42	18,34	31,15	17,25	30,16	4,52	8,28	4,59	8,40
H	2,41	1,78	3,06	1,67	2,94	0,36	1,21	0,33	1,09
I	7,07	6,16	14,85	5,17	11,59	1,11	2,65	1,15	2,91
J	11,78	9,82	23,41	8,62	20,00	3,52	7,33	3,58	7,31
Rata-rata	32,03	27,68	68,32	26,43	66,13	11,58	29,19	11,89	33,37

Rekapitulasi hasil evaluasi performa pengujian *Modeling* untuk setiap skenario dan setiap produk pada Tabel 5 menunjukkan bahwa model yang dilatih menggunakan pengujian skenario 3 yaitu kombinasi fitur deret waktu dan fitur penanda memberikan hasil evaluasi performa terbaik dibandingkan skenario lain dengan nilai MAE dan RMSE yang cenderung paling rendah pada hampir seluruh produk. Nilai MAE dan RMSE yang semakin rendah menunjukkan bahwa model menghasilkan peramalan dengan nilai penyimpangan yang rendah terhadap data uji. Semakin rendah nilai penyimpangan hasil peramalan terhadap data uji menunjukkan bahwa model memiliki performa dan kemampuan yang baik dalam melakukan peramalan, sehingga peramalan yang dihasilkan oleh model dapat diandalkan dan digunakan sebagai acuan dalam proses manajemen persediaan. Nilai evaluasi performa antara pengujian skenario 3 dan pengujian skenario 4 secara keseluruhan hanya terdapat selisih nilai yang kecil dan tidak signifikan.

Rekapitulasi nilai *feature importance* dengan nilai tertinggi pada setiap skenario pengujian dan setiap produk ditunjukkan pada Tabel 6.

Tabel 6. Rekapitulasi Nilai *Feature Importance*

Produk	Skenario 1		Skenario 2		Skenario 3		Skenario 4	
	Nama Fitur (Skor)		Nama Fitur (Skor)		Nama Fitur (Skor)		Nama Fitur (Skor)	
A	Day_of_week (0,595063)		Day_of_week (0,387316)		Num_Bulk Trans (0,909635)		Num_Bulk Trans (0,886382)	
B	Day_of_week (0,788000)		Day_of_week (0,552270)		Num_Transaction (0,762712)		Num_Transaction (0,755577)	
C	Day_of_week (0,511643)		Day_of_week (0,304652)		Num_Transaction (0,574352)		Num_Transaction (0,569019)	
D	Month (0,45903)		Lag_Qty_1 (0,565931)		Num_Transaction (0,951534)		Num_Transaction (0,961726)	
E	Day_of_week (0,79358)		Day_of_week (0,563251)		Num_Transaction (0,768034)		Num_Transaction (0,753133)	
F	Day_of_week (0,840493)		Day_of_week (0,59562)		Num_Transaction (0,838709)		Num_Transaction (0,814962)	
G	Day_of_week (0,802786)		Day_of_week (0,47487)		Num_Bulk Trans (0,515967)		Num_Bulk Trans (0,495338)	
H	Day_of_week (0,590247)		Day_of_week (0,376605)		Num_Transaction (0,872536)		Num_Transaction (0,91872)	
I	Day_of_week (0,607396)		Lag_Qty_7 (0,373413)		Num_Transaction (0,911747)		Num_Transaction (0,898523)	
J	Day_of_week (0,552372)		Lag_Qty_1 (0,263416)		Num_Transaction (0,818723)		Num_Transaction (0,790499)	

Analisis *feature importance* yang dilakukan pada setiap pengujian yang terdapat pada Tabel 6 menunjukkan bahwa pengujian skenario 3 dan pengujian skenario 4 memiliki fitur yang cenderung sama yang sangat berpengaruh terhadap performa model. Fitur yang sangat berpengaruh terhadap performa model dalam pengujian skenario 3 dan

pengujian skenario 4 adalah fitur 'Num\_Transaction' (menunjukkan jumlah transaksi) dan fitur 'Num\_Bulk\_Trans' (menunjukkan jumlah transaksi dengan volume besar).

Analisis faktor penyebab tingginya pengaruh fitur 'Num\_Transaction' pada model di antaranya adalah korelasi langsung dengan kuantitas penjualan. Fitur 'Num\_Transaction' berisi informasi terkait jumlah transaksi penjualan dalam suatu hari. Semakin tinggi jumlah transaksi maka kuantitas penjualan juga akan cenderung tinggi. Fitur 'Num\_Transaction' juga dapat menjadi indikator jumlah pelanggan, Jumlah transaksi yang tinggi dapat menunjukkan jumlah pelanggan yang tinggi sehingga memungkinkan peluang penjualan dengan kuantitas yang lebih banyak. Fitur 'Num\_Transaction' yang menunjukkan jumlah transaksi dapat mencerminkan aktivitas toko pada suatu waktu. Transaksi dengan jumlah yang tinggi mengindikasikan bahwa pada waktu tersebut menghasilkan banyak penjualan dibandingkan waktu lain.

Analisis faktor penyebab tingginya pengaruh fitur 'Num\_Bulk\_Trans' pada model di antaranya adalah fitur 'Num\_Bulk\_Trans' berkorelasi langsung dengan volume Penjualan. Semakin tinggi jumlah transaksi dengan volume yang besar maka kuantitas penjualan juga akan semakin tinggi. Fitur 'Num\_Bulk\_Trans' juga menjadi indikator periode permintaan yang tinggi. Periode permintaan yang tinggi umumnya terjadi karena adanya peristiwa atau kejadian tertentu, seperti contohnya pada periode waktu bulan Ramadan dan menjelang Idul Fitri pembelian dengan volume besar cenderung meningkat pada produk-produk seperti sembako. Fitur 'Num\_Bulk\_Trans' juga dapat menunjukkan indikasi adanya penjualan Bisnis ke Bisnis (B2B) yang umumnya berupa penjualan dalam volume besar dari institusi atau bisnis lain. Contoh transaksi penjualan B2B pada UB Mart adalah permintaan pengadaan suatu produk dari fakultas atau unit di Universitas Brawijaya, seperti pengadaan air mineral untuk keperluan konsumsi rapat atau kegiatan.

## 5. KESIMPULAN DAN SARAN

Evaluasi performa model peramalan penjualan produk pada UB Mart yang dicapai oleh model dengan performa terbaik menggunakan *Extreme Gradient Boosting* (XGBoost) telah dilakukan menggunakan metrik evaluasi *Mean Absolute Error* (MAE) dan *Root Mean Squared Error* (RMSE). Hasil evaluasi menunjukkan bahwa model XGBoost yang dilatih dengan fitur yang tepat dapat menghasilkan nilai MAE dan RMSE yang rendah. Nilai MAE dalam konteks bisnis memberikan gambaran yang jelas terkait rata-rata kesalahan mutlak dalam peramalan penjualan yang jika diinterpretasikan ke dalam lingkup operasional bisnis seperti stok yang berlebih atau kekurangan stok. Nilai RMSE di sisi lain menekankan bobot kesalahan yang lebih tinggi pada kesalahan yang lebih besar sehingga memberikan

pandangan terkait distribusi kesalahan prediksi. Model dengan performa terbaik yang berhasil dicapai terdapat pada model dengan pengujian skenario 3 dengan rata-rata nilai MAE model dari seluruh produk terpilih sebesar 11,58 dan rata-rata nilai RMSE model dari seluruh produk terpilih sebesar 29,19. Model dengan performa terburuk adalah model dengan pengujian skenario 1 dengan rata-rata nilai MAE model dari seluruh produk terpilih sebesar 27,68 dan rata-rata nilai RMSE model dari seluruh produk terpilih sebesar 68,32.

Saran untuk pengembangan pada penelitian selanjutnya antara lain yaitu menggunakan informasi eksternal tambahan terkait kejadian atau waktu tertentu yang dapat memengaruhi peningkatan penjualan. Informasi eksternal tambahan yang dimaksud seperti tanggal pembagian sisa hasil usaha (SHU), promosi khusus, acara tahunan, atau kegiatan lain yang memiliki dampak signifikan terhadap penjualan. Optimasi performa model juga dapat ditingkatkan dengan melakukan *hyperparameter tuning* model XGBoost secara lebih lanjut.

## DAFTAR PUSTAKA

- CHAPMAN, P., CLINTON, J., KERBER, R., KHABAZA, T., REINARTZ, T., SHEARER, C. DAN WIRTH, R., 2000. *CRISP-DM 1.0: Step-by-step Data Mining Guide*. [daring] Tersedia pada: <<http://www.crisp-dm.org/CRISPWP-0800.pdf>>.
- FERNIE, J. DAN SPARKS, L., 2019. *Logistics and Retail Management: Emerging Issues and New Challenges in the Retail Supply Chain*. 5th ed. [daring] Kogan Page. Tersedia pada: <<https://books.google.co.id/books?id=vU51DwAAQBAJ>>.
- GUINOUBI, S., HANI, Y. DAN ELMHAMED, A., 2021. Demand forecast; a case study in the agri-food sector: Cold. *IFAC-PapersOnLine*, [daring] 54(1), hal.993–998. <https://doi.org/10.1016/j.ifacol.2021.08.19>.
- HAJJAH, A. DAN MARLIM, Y.N., 2021. Analisis Error Terhadap Peramalan Data Penjualan. *Techno.Com*, 20(1), hal.1–9. <https://doi.org/10.33633/tc.v20i1.4054>.
- HEIZER, J., RENDER, B. DAN MUNSON, C., 2017. *Operations Management*. 12th ed. London: Pearson Education.
- HERIANSYAH, E. DAN HASIBUAN, S., 2018. Implementasi Metode Peramalan pada Permintaan Bracket Side Stand K59A. *Jurnal PASTI*, 12(2), hal.209–223.
- HUSEIN, A.M., LUBIS, F.R. DAN HARAHA, M.K., 2021. Analisis Prediktif untuk Keputusan Bisnis: Peramalan Penjualan. *Data Sciences Indonesia (DSI)*, 1(1), hal.32–40. <https://doi.org/10.47709/dsi.v1i1.1196>.

- HYNDMAN, R.J. DAN ATHANASOPOULOS, G., 2021. *Forecasting : Principles and Practice*. 3rd ed. Otexts.
- MARTINEZ-PLUMED, F., CONTRERAS-OCHANDO, L., FERRI, C., HERNANDEZ-ORALLO, J., KULL, M., LACHICHE, N., RAMIREZ-QUINTANA, M.J. DAN FLACH, P., 2021. CRISP-DM Twenty Years Later: From Data Mining Processes to Data Science Trajectories. *IEEE Transactions on Knowledge and Data Engineering*, 33(8), hal.3048–3061. <https://doi.org/10.1109/TKDE.2019.2962680>.
- PUARNAMASARI, D.I., PERMADI, V.A., SAEPUKIN, A. DAN AGUSDIN, R.P., 2023. Demand Forecasting for Improved Inventory Management in Small and Medium-Sized Businesses. *JANAPATI: Jurnal Nasional Pendidikan Teknik Informatika*, [daring] 12(1), hal.56–66. Tersedia pada: <<https://ejournal.undiksha.ac.id/index.php/janapati/article/view/57144>>.
- RIZA, F., 2022. Analisis dan Prediksi Data Penjualan Menggunakan Machine Learning dengan Pendekatan Ilmu Data. *Data Sciences Indonesia (DSI)*, 1(2), hal.62–68. <https://doi.org/10.47709/dsi.v1i2.1308>.
- XGBoost Developers, 2022. XGBoost Documentation. [daring] Tersedia pada: <<https://xgboost.readthedocs.io/>>.
- YANG, T., 2023. Sales Prediction of Walmart Sales Based on OLS, Random Forest, and XGBoost Models. *Highlights in Science, Engineering and Technology*, 49, hal.244–249. <https://doi.org/10.54097/hset.v49i.8513>.
- YULIANTI, S.E.H., SOESANTO, O. DAN SUKMAWATY, Y., 2022. Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit. *Journal of Mathematics: Theory and Applications*, 4(1), hal.21–26. <https://doi.org/10.31605/jomta.v4i1.1792>.
- ZHANG, L., BIAN, W., QU, W., TUO, L. DAN WANG, Y., 2021. Time series forecast of sales volume based on XGBoost. *Journal of Physics: Conference Series*, 1873(1). <https://doi.org/10.1088/1742-6596/1873/1/012067>.

*Halaman ini sengaja dikosongkan*